

---

---

---

---

---



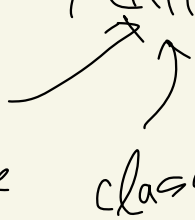
기장 (GDA)  
 Generative vs Discriminative.  
 naive Bayes

→ Logistic Regression / Aggression  
 0.0  
 update 매개변수 정리를 하는 것.

이전 분류기들 다들 참으니까

## Generative learning Algorithms.

각각 class에 대한 model  
 구축할 수 있는 model 과 비교

Discriminative	Generative
learn $P(x y)$ (or learn $h(x) = y$ ) $x \rightarrow y$	learn $P(x y)$  feature      class $P(x) : \text{class prior}$

# Bayes Rule

이항분포 확률 (이항 1항이 불확실 (양성성 확률))

$$P(Y=1 | X) = \frac{P(X|Y=1)P(Y=1)}{P(X)}$$

$$= P(X|Y=1)P(Y) + P(X|Y=0)P(Y=0)$$

## Generative Learning Algorithm

### Gaussian Discriminant Analysis

Suppose  $X \in \mathbb{R}^n$  (drop  $X_0=1$  convention)

Assume  $P(X|Y)$  is Gaussian

\* 다항식 근사

$$Z \sim N(\mu, \Sigma)$$

$$\text{parameter: } \mu \in \mathbb{R}^n, \Sigma \in \mathbb{R}^{n \times n}$$

$$P(x, \mu, \Sigma) = \frac{1}{(2\pi)^n |\Sigma|} \exp\left(-\frac{1}{2}(x-\mu)^T \Sigma^{-1}(x-\mu)\right)$$

$\mu$ : 중심 위치를 결정  
[0]

$\Sigma$ : 분산 정도를 결정  
[0]

[0]

\*  $\mu, \Sigma$  파라미터 값 결정

GDA model.  $p(x|y)$ 을 Gaussian이라고.

$$p(x|y=0) = \text{Gaussian}, \quad p(x|y=1) = \text{Gaussian}$$

일부인  $\mu_0, \mu_1$  두개의 class에 같은  $\Sigma$  shared parameter  $\mu_0, \mu_1$

$$p(y) = \text{Bernoulli} = \phi^y (1-\phi)^{1-y} \quad (p(y=1) = \phi)$$

$$\text{total Parameters: } \mu_0, \mu_1, \Sigma, \phi$$

$\mathbb{R}^D \quad \mathbb{R}^{D \times D} \quad \mathbb{R}$

이러한 parameter 들은 전체 dataset을 이용하여

\*  $\phi$ 를 위해서 Max Joint Likelihood

$$L(\phi, \mu_0, \mu_1, \Sigma) = \prod_{i=1}^n p(x^{(i)} | y^{(i)}) p(y^{(i)})$$

→  $x, y$  pair의 joint likelihood를  
각 Discriminative Conditional likelihood로 세어.

$$\rightarrow \text{likelihood를 Max 하는 } \phi = \frac{\sum_{i=1}^n y^{(i)}}{n}$$

$$\text{indicator function} = \frac{\sum_{i=1}^n \mathbb{1}(y^{(i)}=1)}{n} \quad \mathbb{1}(y=1) = 1$$

$\mathbb{1}(y=0) = 0$


$$\mu_0 = \frac{\sum_{k=1}^N 1_{y^{(k)}=0} x^{(k)}}{\sum_{k=1}^N 1_{y^{(k)}=0}} \leftarrow y=0 \text{인 vector들의 평균}$$

$$\Sigma = \frac{1}{n} \sum_{i=1}^N (x^{(i)} - \mu(x^{(i)})) (x^{(i)} - \mu(x^{(i)}))^T$$

이제 parameter 알았으니 prediction 시작 함.

$$\arg \max_y p(y|x) = \arg \max_y \frac{p(x|y)p(y)}{p(x)} \leftarrow \text{이것} = \arg \max_y p(x|y)p(y)$$

Compare GDA with Logistic Regression



→ 이렇게/이 확률함수가 있는 한때  $p(y=1 | x; \theta, \Sigma, \mu_0, \mu_1) = \frac{1}{1 + \exp(-\theta^T x)}$

GDA와/이  $y=1$ 인 것  $p(y=1|x)$  modeling을  
Logistic 확률함수함.

→ 2개의 값을 모두 ignore 하는 게 좋음.

$$S_{DA} \xrightarrow{\text{red circle}} p(y=1|x) = \frac{1}{1+e^{-\theta x}}$$

← red X

따라서 S<sub>DA</sub>는 더 좋은 특징을 가지는 일반성을 갖는 data set에 더 적합함.

## Naive Bayes

S<sub>DA</sub>는 편향되었기 때문에, Naive Bayes (Generative Learning Algorithm)

예) 이메일 스팸 필터  $n=10,000$

Feature vector  $x$ ? / 각 단어가 등장하면: 1, 등장하지 않음: 0

$$x_i \in \{0, 1\}^n$$

$x_i = 1$  if word  $i$  appears in email

want to model  $p(x|x)$  ← 이대로 하면 파라미터가

2<sup>10,000</sup>에 달하기 때문에 불가능

대안

Assume  $x_i$ 's are conditionally independent given  $y$

$$= p(x_1, x_2, \dots, x_{10000} | y) = p(x_1 | y) p(x_2 | y) p(x_3 | y) \dots p(x_n | y) = \prod_{i=1}^n p(x_i | y)$$

